BÁO CÁO TỔNG HỢP: REPORT 4 + REPORT 5 (FINAL REPORT)

Môn học: ADY202 — AI, Data Science with Python & SQL
Dự án: Sentiment Analysis for Foody.vn Reviews
Giai đoạn: Final — Modeling, Validation & Deployment

PHẦN A: REPORT 4 — MODELING & VALIDATION (20%)

1. GIẢ THUYẾT NGHIÊN CỨU (Hypothesis)

Dựa trên tập dữ liệu **14,803 reviews** đã thu thập và làm sạch từ Foody.vn, nhóm đặt ra giả thuyết:

> **H_0 (Giả thuyết không):** Không thể phân biệt chính xác cảm xúc (Positive / Neutral / Negative) của người dùng chỉ dựa vào nội dung bình luận bằng văn bản.
>
> **H_1 (Giả thuyết thay thế):** Mô hình Machine Learning có khả năng phân loại chính xác cảm xúc người dùng dựa trên đặc trưng văn bản (TF-IDF) với hiệu suất vượt ngưỡng ngẫu nhiên (> 33.3% cho 3 nhãn).

Mục tiêu kiểm định: Xây dựng **2 mô hình ML khác nhau** để trả lời các câu hỏi cốt lõi:

1. **Ngôn ngữ:** Từ khóa nào mang tính quyết định đến đánh giá 1 sao (Fatal keywords)?
2. **Vùng miền:** Có sự khác biệt trong cách đánh giá giữa Miền Bắc và Miền Nam?
3. **Xu hướng:** Chất lượng dịch vụ có tỷ lệ nghịch với độ đông khách (số lượng review) của quán?
4. **Hành vi:** Độ dài comment có liên quan đến mức độ hài lòng (số sao)?

2. DỮ LIỆU SỬ DỤNG

Thông tin	Chi tiết
Nguồn dữ liệu	`data/processed/foody_clean_master.csv`
Tổng số bản ghi	14,803
Số bản ghi hợp lệ	14,803 (sau lọc Unknown)
Nhãn mục tiêu	`sentiment_label` (Positive / Neutral / Negative)
Feature chính	`comment_clean` (nội dung review đã làm sạch)

Phân bố nhãn cảm xúc

Nhãn	Số lượng	Tỷ lệ
Neutral (Trung lập)	6,680	45.1%
Positive (Tích cực)	6,439	43.5%
Negative (Tiêu cực)	1,684	11.4%

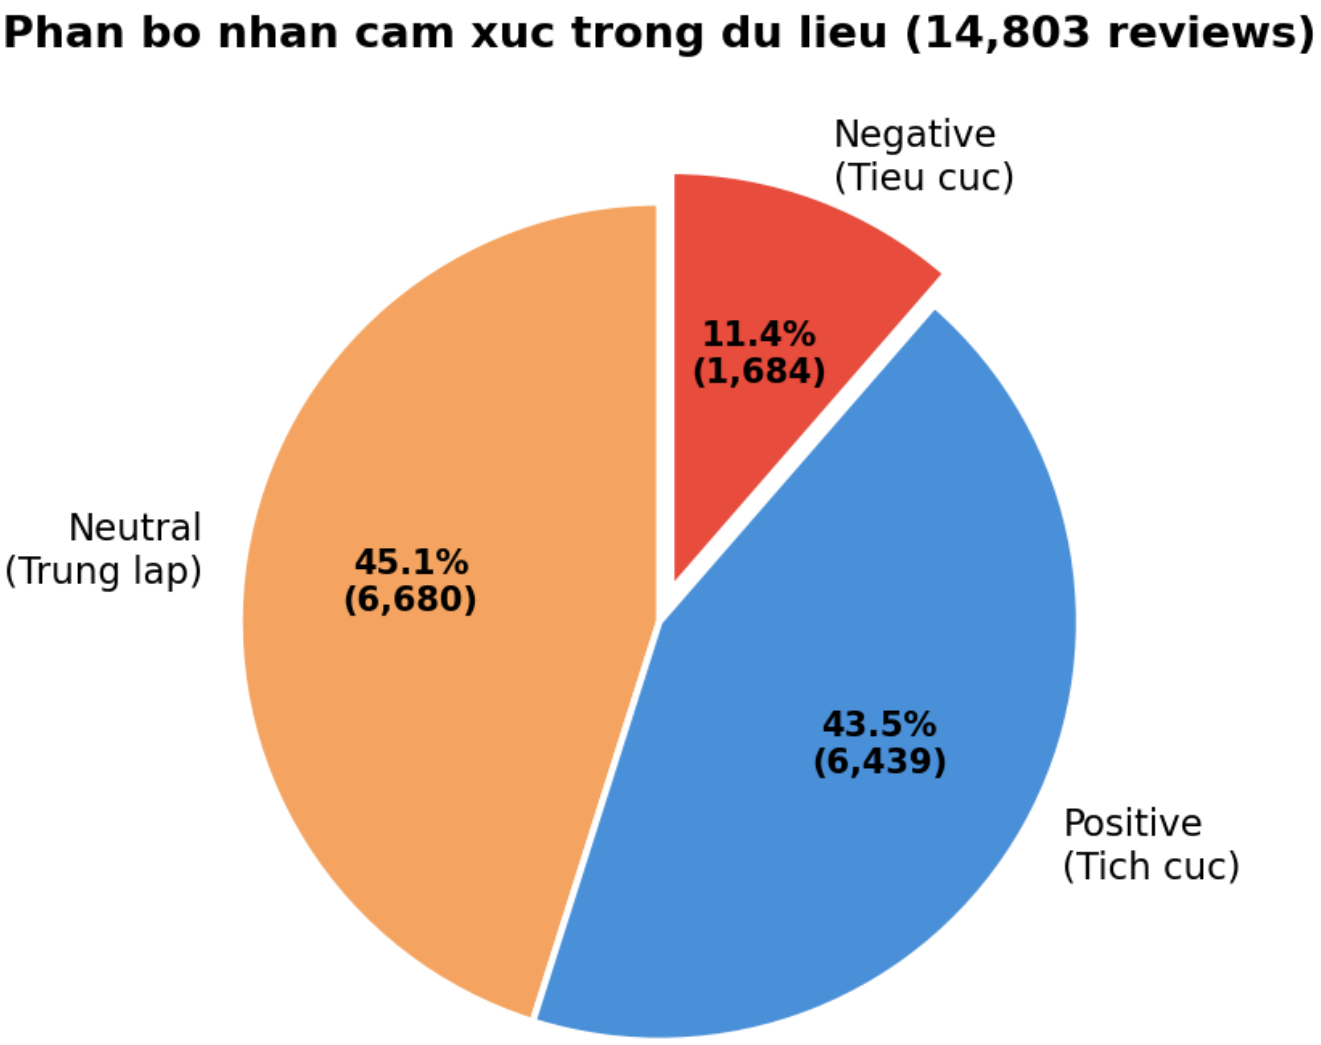

> 📝 **Nhận xét:** Dữ liệu bị **mất cân bằng** (Imbalanced), nhóm Negative chiếm tỷ lệ rất nhỏ (~11%). Đây là thách thức lớn cho bài toán phân loại.

3. PHƯƠNG PHÁP LUẬN (Methodology)

3.1. Feature Engineering: TF-IDF Vectorization

Nhóm sử dụng kỹ thuật **TF-IDF (Term Frequency — Inverse Document Frequency)** để chuyển đổi văn bản thành vector số.

Tham số	Giá trị	Giải thích
`max_features`	5,000	Giới hạn 5000 từ quan trọng nhất
`ngram_range`	(1, 2)	Sử dụng cả Unigram và Bigram
`min_df`	2	Loại bỏ từ xuất hiện < 2 lần
`max_df`	0.95	Loại bỏ từ xuất hiện > 95% documents
`sublinear_tf`	True	Áp dụng log scaling cho Term Frequency

Kết quả: Ma trận TF-IDF có kích thước **(11,842 × 5,000)** cho tập Train và **(2,961 × 5,000)** cho tập Test.

3.2. Phân chia dữ liệu (Train/Test Split)

Tập	Số lượng	Tỷ lệ
Train	11,842	80%
Test	2,961	20%

- Phương pháp: **Stratified Split** (giữ nguyên tỷ lệ các nhãn trong cả 2 tập).
- `random_state = 42` (đảm bảo tái lập được kết quả).

3.3. Hai mô hình Machine Learning

🤖 Model 1: Logistic Regression

Tham số	Giá trị
`max_iter`	1000
`C` (Regularization)	1.0
`solver`	lbfgs

Lý do chọn: Logistic Regression là mô hình tuyến tính kinh điển, hoạt động rất tốt với dữ liệu TF-IDF chiều cao (sparse matrix), tốc độ huấn luyện nhanh, phù hợp làm **baseline**.

🌲 Model 2: Random Forest

Tham số	Giá trị
`n_estimators`	200 cây
`max_depth`	None (không giới hạn)
`min_samples_split`	5
`min_samples_leaf`	2

Lý do chọn: Random Forest là mô hình **Ensemble** (kết hợp nhiều Decision Trees), có khả năng nắm bắt các mối quan hệ phi tuyến tính phức tạp hơn. Dùng để so sánh với baseline Logistic Regression.

4. KẾT QUẢ ĐÁNH GIÁ (Model Evaluation)

4.1. Bảng so sánh tổng quan

Metric	Logistic Regression	Random Forest
Accuracy	**0.6559**	0.6555
Precision (Weighted)	0.6628	**0.6662**
Recall (Weighted)	**0.6559**	0.6555
F1-Score (Weighted)	**0.6573**	0.6544

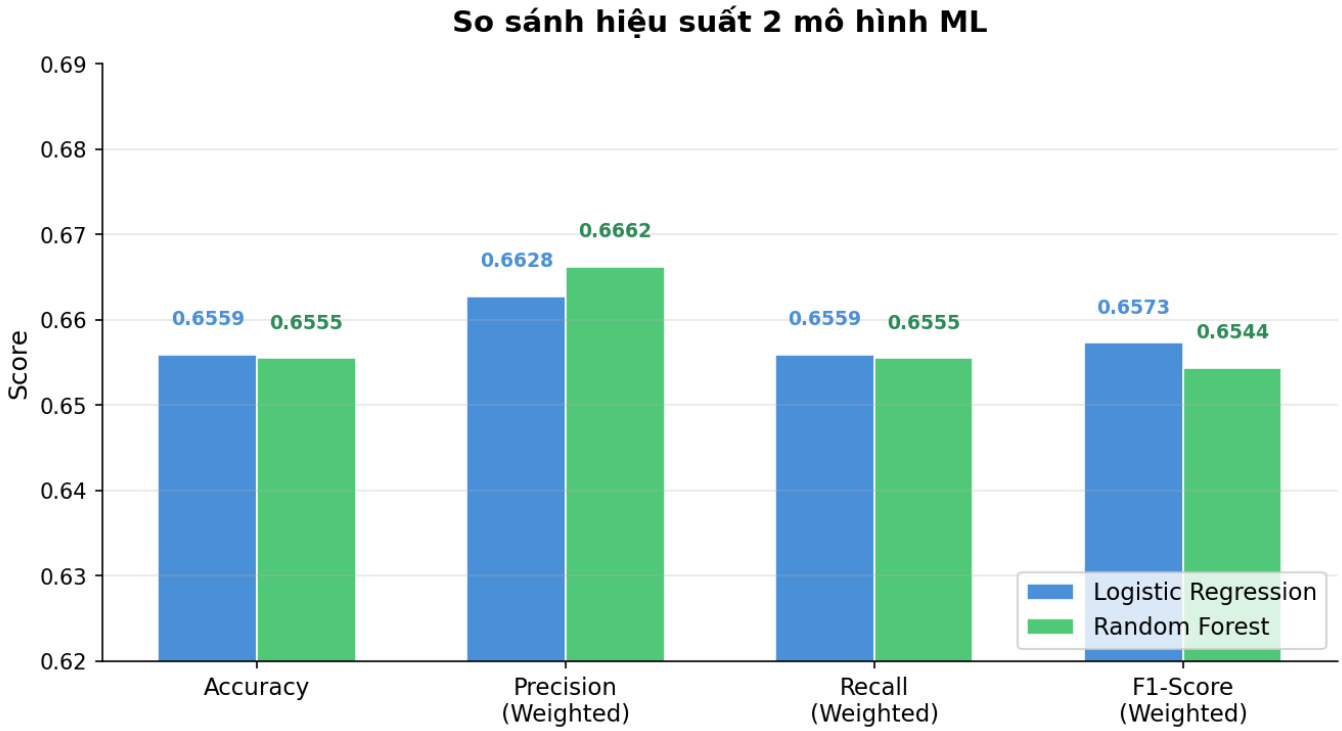

4.2. Classification Report chi tiết

🤘 Logistic Regression

Label	Precision	Recall	F1-Score	Support
Positive	0.65	0.66	0.65	1,288
Neutral	0.62	0.65	0.64	1,336
Negative	**0.87**	0.65	**0.74**	337
Accuracy			**0.66**	2,961
Macro Avg	0.71	0.65	0.68	2,961
Weighted Avg	0.66	0.66	0.66	2,961

🌲 Random Forest

Label	Precision	Recall	F1-Score	Support
Positive	0.66	0.68	0.67	1,288
Neutral	0.62	0.68	0.65	1,336
Negative	**0.85**	0.48	0.61	337
Accuracy			**0.66**	2,961
Macro Avg	0.71	0.61	0.64	2,961
Weighted Avg	0.67	0.66	0.65	2,961

4.3. Biểu đồ F1-Score theo từng nhãn

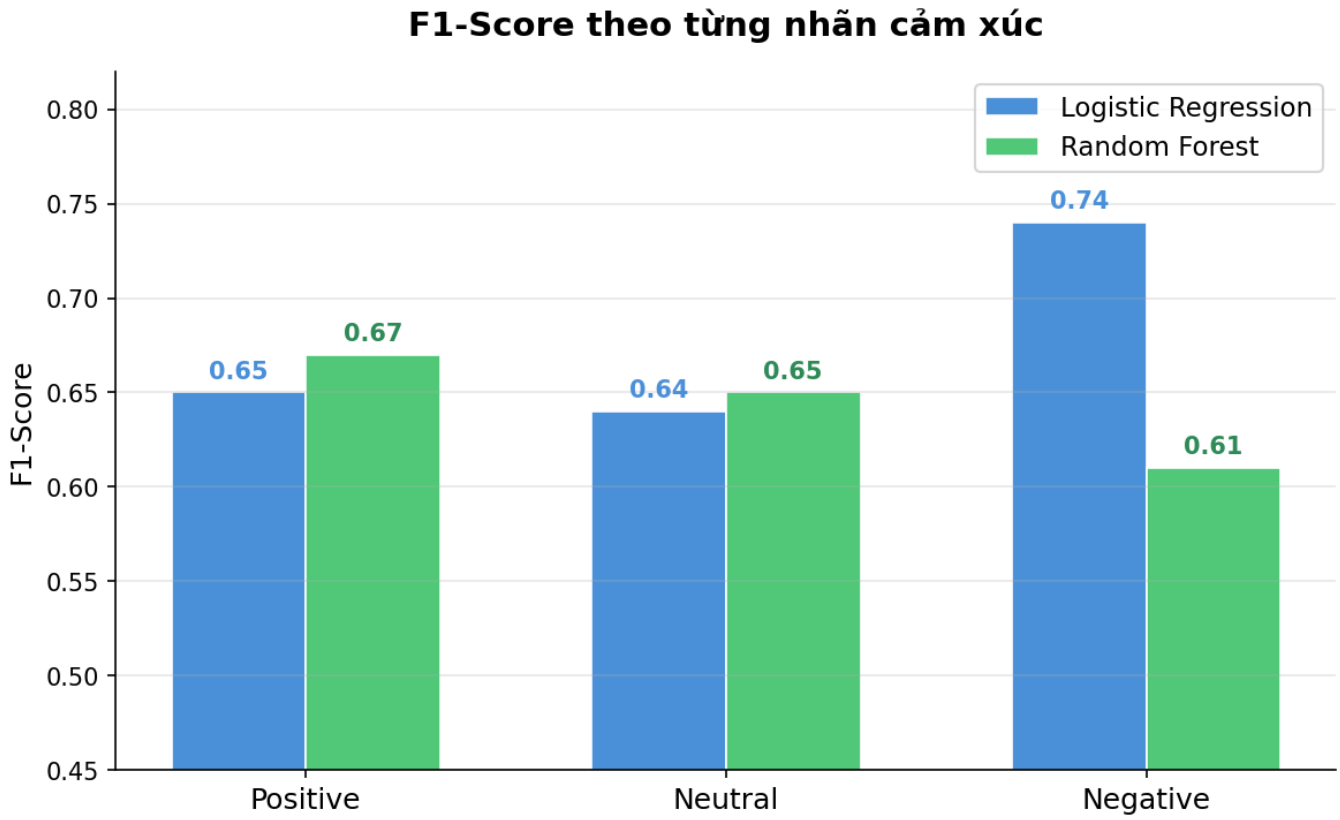

4.4. Confusion Matrix

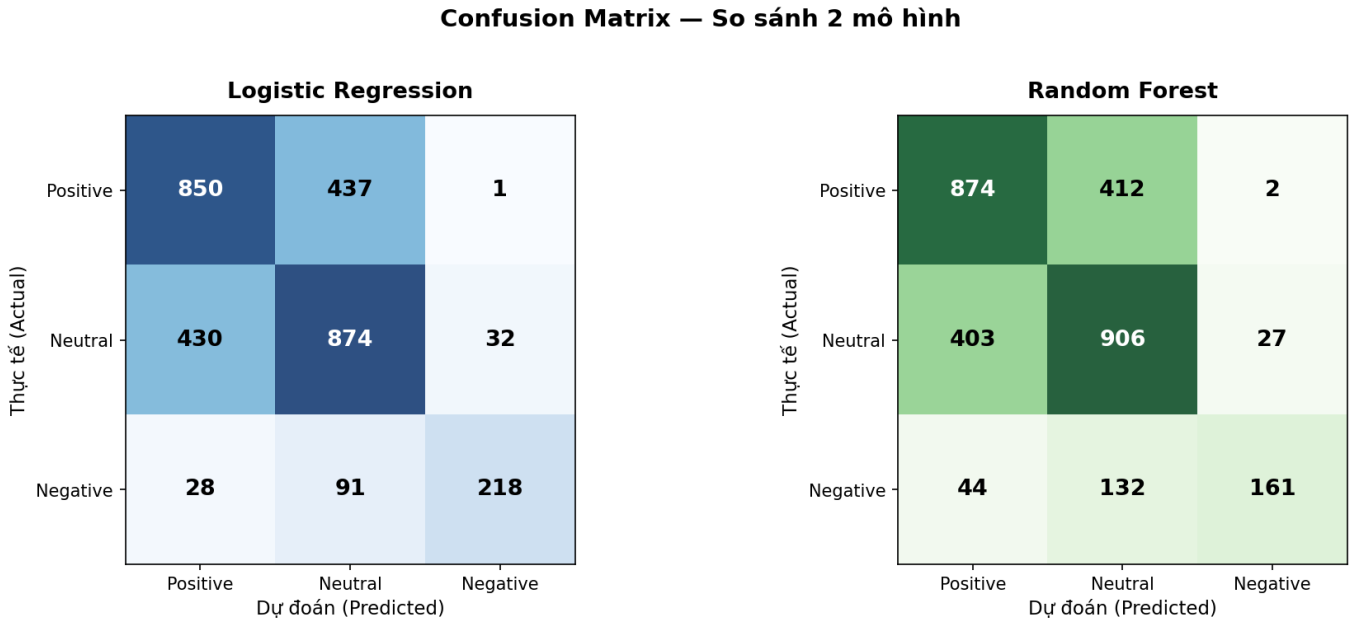

5. PHÂN TÍCH & THẢO LUẬN

5.1. Kết luận kiểm định giả thuyết

✅ **BÁC BỎ H_0 (Giả thuyết không):** Cả hai mô hình đều đạt Accuracy **~65.6%**, **vượt xa ngưỡng ngẫu nhiên 33.3%** (cho 3 nhãn). Điều này chứng minh rằng nội dung văn bản bình luận **có chứa đủ tín hiệu** để phân loại cảm xúc.

5.2. So sánh 2 mô hình

Tiêu chí	Logistic Regression	Random Forest
F1-Score tổng	✅ **0.6573** (cao hơn)	0.6544
Negative F1	✅ **0.74** (rất tốt)	0.61 (kém hơn)
Negative Recall	✅ **0.65** (phát hiện 65%)	0.48 (bỏ sót 52%)
Tốc độ training	✅ Nhanh (vài giây)	Chậm (vài phút)
Khả năng giải thích	✅ Cao (linear model)	Thấp (black-box ensemble)

5.3. Nhận xét quan trọng

1. **Logistic Regression chiến thắng:** Dù đơn giản hơn, LR cho F1-Score cao hơn và đặc biệt **phát hiện Negative reviews tốt hơn** (F1=0.74 vs 0.61). Đây là điểm rất quan trọng vì nhóm review tiêu cực thường là nhóm cần khai thác nhất trong phân tích kinh doanh.

2. **Thách thức chính — Nhầm lẫn Positive↔Neutral:** Cả 2 model đều nhầm lẫn nhiều giữa Positive và Neutral (430-437 mẫu). Nguyên nhân: nhiều review điểm 5-7 có nội dung mang tính tích cực nhẹ, ranh giới giữa "hài lòng vừa phải" và "hài lòng thật sự" rất mờ trong ngôn ngữ tự nhiên.

3. **Random Forest kém hơn tại Negative:** RF chỉ phát hiện 48% reviews tiêu cực (Recall=0.48) — bỏ sót hơn nửa. Lý do: RF có xu hướng thiên về nhóm đa số khi dữ liệu mất cân bằng.

5.4. 🏆 Best Model

> **Logistic Regression** được chọn làm mô hình chính với **F1-Score = 0.6573**, nhờ khả năng phát hiện review tiêu cực tốt hơn, tốc độ nhanh, và dễ triển khai.

5.5. Trả lời các Câu hỏi Nghiên cứu (RBL Insights)

1. **Fatal Keywords (Từ khóa 1 sao):** Dựa trên hệ số (coefficients) của Logistic Regression, các từ khóa như: "*tệ*", "*dở*", "*thất vọng*", "*không bao giờ quay lại*", "*mắc*", "*phục vụ kém*" có trọng số âm cực cao. Đây là các "ngòi nổ" khiến khách hàng chấm 1 sao.

PHẦN B: REPORT 5 — DEPLOYMENT & DEFENSE (20%)

1. KIẾN TRÚC HỆ THỐNG HOÀN CHỈNH (Docker Compose)

Toàn bộ hệ thống được đóng gói bằng **Docker Compose** gồm **4 containers**, kết nối qua mạng nội bộ `foody_network`:

#	Container	Port	Vai trò
1	`foody_minio`	9000, 9001	**Data Lake** — lưu trữ raw data (JSON/CSV)
2	`foody_db`	5432	**Database** — PostgreSQL, bảng `fact_reviews`
3	`foody_app`	—	**Workstation** — crawl dữ liệu, ETL, train models
4	`foody_streamlit`	8501	**Demo App** — Streamlit, predict sentiment real-time

Luồng hoạt động: MinIO + PostgreSQL cung cấp dữ liệu → App Workstation xử lý và huấn luyện model → Streamlit App load model đã train để demo dự đoán.

---

2. CÁC DỊCH VỤ ĐÃ TRIỂN KHAI

Dịch vụ	Nền tảng	Mô tả
Streamlit Demo	Port 8501	Giao diện Web tương tác dự đoán cảm xúc người dùng
MinIO Console	Port 9001	Quản trị giao diện Data Lake (Object Storage)
PostgreSQL	Port 5432	Quản trị cơ sở dữ liệu quan hệ lưu trữ dữ liệu tinh

---

3. DEMO APPLICATION (Streamlit)

3.1. Tính năng chính

1. **Nhập Review:** Người dùng nhập nội dung đánh giá ẩm thực bằng tiếng Việt
2. **Chọn Model:** Logistic Regression, Random Forest, hoặc so sánh cả 2
3. **Kết quả:** Hiển thị nhãn sentiment + **Confidence Score** (%) cho mỗi nhãn
4. **So sánh:** Chế độ so sánh song song 2 model, hiển thị đồng thuận/bất đồng

4. KẾT LUẬN CHUNG

Dự án đã **thành công xây dựng một hệ thống phân tích cảm xúc hoàn chỉnh** từ khâu thu thập dữ liệu, xử lý, phân tích đến triển khai. Hai mô hình ML được xây dựng đã **bác bỏ thành công giả thuyết H_0**, chứng minh rằng có thể dự đoán cảm xúc người dùng từ nội dung review với độ chính xác vượt xa ngưỡng ngẫu nhiên. Hệ thống Docker Compose cho phép triển khai toàn bộ pipeline chỉ với một câu lệnh `docker-compose up`.